

CPU vs GPU untuk Beban Kerja AI

Benchmark terukur pada NVIDIA GeForce RTX 3070 Ti Laptop GPU
dengan Keras 3

2026-09-04

Daftar Isi

Ringkasan	2
Kenapa benchmark ini bisa dipercaya	3
Delapan kasus uji	4
Hasil pengukuran	5
GEMM fp32 (GFLOP/s)	5
Titik potong: throughput vs ukuran batch	7
Overhead <code>model.fit</code> (sampel/detik)	7
Training penuh (<code>model.fit</code> , detik per epoch)	8
XLA <code>jit_compile</code> pada CNN (sampel/detik)	8
Inference: latensi vs throughput	9
Mixed precision bf16 (GPU saja, sampel/detik)	10
Tabel gabungan	10
Kapan memakai CPU, kapan GPU	11
Kaitan dengan rencana riset	12
Cara menjalankan ulang	13
Lampiran: kode lengkap	14

Ringkasan

Dokumen ini membandingkan CPU dan GPU untuk beban kerja AI pada satu perangkat nyata: laptop dengan **NVIDIA GeForce RTX 3070 Ti Laptop GPU** dan **Intel Core i9-12900H** yang dijalankan di WSL2. Semua angka di sini diukur langsung di mesin tersebut, bukan dikutip dari spesifikasi pabrikan atau dari benchmark publik. Preset yang dipakai: **standard**.

Tiga temuan utama:

1. GPU tidak selalu lebih cepat. GPU baru mulai menang pada ukuran batch **128**. Di bawah itu CPU justru lebih cepat, karena setiap langkah training di GPU membawa biaya tetap (peluncuran kernel, sinkronisasi, dispatch dari Python) yang tidak bergantung pada besar batch.

2. Selisihnya sangat bergantung jenis operasi. Pada perkalian matriks fp32 murni, GPU mencapai **4,545 GFLOP/s** melawan **398 GFLOP/s** di CPU — sekitar **11.4x**. Angka ini adalah *plafon*: tidak ada beban kerja nyata dalam laporan ini yang speedup-nya melampauinya. Pada training penuh, perolehan terbesar ada di transformer (**4.0x**), jauh di bawah plafon GEMM tadi. Jarak antara plafon dan beban kerja nyata itulah inti persoalannya: yang hilang di antaranya adalah operasi kecil, sinkronisasi, dan lapisan yang tidak menyatu menjadi satu kernel.

3. Untuk inference, ukuran batch menentukan segalanya. Pada batch 1, GPU sering hanya imbang atau bahkan kalah, karena waktu yang terukur didominasi latensi peluncuran kernel dan transfer data, bukan komputasi. Keunggulan GPU muncul saat batch besar, ketika 46 SM benar-benar terisi.

Konsekuensi praktisnya sederhana: **GPU pada perangkat ini adalah mesin throughput, bukan mesin latensi.** Ia membayar biaya tetap di awal setiap langkah, lalu mengerjakan pekerjaan besar nyaris gratis. Kalau pekerjaan yang diberikan kecil, biaya tetap itu yang mendominasi dan CPU menang.

Lingkungan uji: TensorFlow 2.21.0, Keras 3.15.1, 6 thread CPU terlihat di WSL, TF32 aktif.

Kenapa benchmark ini bisa dipercaya

Sebagian besar perbandingan CPU-vs-GPU yang beredar salah ukur. Enam hal berikut adalah yang membedakan angka yang bermakna dari angka yang kebetulan.

Isolasi device lewat proses terpisah. TensorFlow menempatkan operasi ke GPU sejak inisialisasi. Menulis `with tf.device('/CPU:0')` di proses yang sudah melihat GPU tidak cukup — sebagian op tetap bocor ke GPU dan hasil “CPU” jadi terlalu bagus. Skrip ini menjalankan sisi CPU sebagai proses anak dengan `CUDA_VISIBLE_DEVICES=-1`, lalu memeriksa ulang bahwa GPU benar-benar tidak terlihat sebelum mengukur apa pun.

Warm-up selalu dibuang. Iterasi pertama berisi penelusuran (*tracing*) `tf.function`, autotune algoritma cuDNN, dan alokasi memori pertama. Itu biaya sekali jalan, bukan biaya komputasi. Memasukkannya ke hasil bisa melipatgandakan angka GPU secara keliru.

Sinkronisasi device sebelum timer ditutup. Ini kesalahan paling umum. Eksekusi GPU bersifat asinkron: `model(x)` kembali ke Python sebelum kernelnya selesai. Tanpa sinkronisasi eksplisit, yang terukur adalah kecepatan Python melempar perintah — biasanya menghasilkan “speedup” 100x yang tidak nyata. Setiap timer di sini ditutup dengan sinkronisasi device.

Setiap kasus dijalankan di proses sendiri. Ini ditemukan secara empiris, bukan direncanakan. Pada versi pertama skrip ini seluruh kasus berbagi satu proses, dan CNN — yang berjalan menjelang akhir — melaporkan GPU lebih lambat daripada CPU. Penyebabnya adalah kondisi yang diwariskan kasus-kasus sebelumnya: fragmentasi VRAM dan, terutama, GPU yang sudah panas. Setiap kasus kini memakai prosesnya sendiri.

Isolasi itu mengurangi masalahnya, tetapi jujur saja **tidak menghilangkannya**. CNN yang sama, diukur pada mesin yang benar-benar dingin, memberi sekitar 1030 sampel/detik di GPU; diukur di tengah rangkaian benchmark — meski di proses terpisah — sekitar 770. Selisih 30% itu murni termal, dan ini laptop: frekuensi GPU dan CPU turun saat panas, dan tidak ada yang bisa dilakukan skrip untuk mencegahnya.

Untuk beban yang pendek dan padat komputasi, efeknya bahkan lebih besar. GEMM 2048x2048 yang dijalankan sendirian pada mesin dingin mencapai sekitar 10.500 GFLOP/s; angka yang sama di tengah rangkaian benchmark

turun ke sekitar 4.500 — lebih dari dua kali lipat selisihnya. Penyebabnya adalah *boost clock*: burst pendek pada GPU dingin berjalan pada frekuensi yang tidak bisa dipertahankan.

Karena itu, dua aturan membaca laporan ini. **Angka absolut punya ketidakpastian besar** — anggap $\pm 30\%$ untuk beban panjang, dan bisa 2x untuk burst pendek seperti GEMM. **Rasio CPU-GPU jauh lebih andal**, karena kedua sisi diukur dalam kondisi termal yang berdekatan, dan itulah sebabnya laporan ini menekankan rasio. Untuk angka absolut yang bersih, jalankan satu kasus saja pada mesin dingin.

Median, bukan rata-rata. Di WSL, satu iterasi bisa tertunda oleh penjadwal atau thermal throttling. Rata-rata menyerap pencilan itu; median tidak.

Data sintetis dengan seed tetap. Untuk mengukur *waktu*, isi data tidak berpengaruh — yang penting bentuk tensor dan jumlah operasinya identik di kedua device. Keuntungannya: tidak ada dependensi unduhan, dan pengukuran bisa diulang persis. Yang tidak diukur di sini adalah akurasi model; itu memang bukan tujuan benchmark ini.

Batas memori dihormati. Setiap kasus dirancang muat di bawah 4 GB VRAM dari 8 GB yang tersedia, dan di bawah 3 GB RAM. `set_memory_growth` diaktifkan supaya TensorFlow tidak langsung mencaplok seluruh VRAM — tanpa itu, penggunaan memori puncak tidak terbaca dan proses lain ikut tercekik.

Satu hal yang **tidak** dikendalikan: perangkat ini laptop. Frekuensi CPU dan GPU turun saat panas. Jalankan ulang saat mesin dingin bila angka terasa aneh, dan perhatikan kolom `p90` pada JSON keluaran sebagai indikator kestabilan.

Delapan kasus uji

Kasus disusun dari yang paling sintetis ke yang paling menyerupai pekerjaan nyata. Dua kasus pertama menjelaskan *kenapa* kasus berikutnya berperilaku seperti itu.

1. GEMM (perkalian matriks). Matriks $N \times N$ butuh $2N^3$ operasi titik-mengambang. Ini kasus paling menguntungkan GPU: padat komputasi, pola akses memori teratur, tanpa cabang. Fungsinya sebagai plafon — batas atas

speedup yang mungkin dicapai pada perangkat ini.

2. Sapuan ukuran batch. Satu langkah training MLP diulang pada batch 128 sampai 8192. Ini kasus paling penting dalam dokumen ini, karena ia memisahkan biaya tetap per langkah dari biaya komputasi yang sebanding dengan beban.

3. Overhead `model.fit`. Default Keras adalah `steps_per_execution=1`: setiap langkah kembali ke Python dan menyinkronkan device untuk mengagregasi loss. Kasus ini membandingkannya dengan `steps_per_execution=32`, yang menjalankan 32 langkah dalam satu panggilan graph.

4. Training MLP. Jaringan *dense* 1.5 juta parameter. Murni matmul, tanpa konvolusi, dengan langkah yang pendek — wakil dari model kecil.

5. Training CNN. Enam lapis konvolusi pada citra 32x32. Konvolusi adalah operasi yang paling diuntungkan cuDNN dan Tensor Core; di sinilah selisih CPU-GPU paling lebar.

6. Training transformer encoder. Empat lapis, `d_model` 256, panjang sekuens 128. Bentuk beban kerjanya sengaja dibuat sama dengan *fine-tuning* BERT/DeBERTa untuk klasifikasi kalimat, hanya lebih kecil supaya sisi CPU selesai dalam waktu wajar.


7. Inference pada beberapa ukuran batch. Hanya *forward pass*, tanpa gradien dan tanpa optimizer. Diukur pada batch 1 sampai 512 untuk menemukan di titik mana GPU mulai unggul.

8. XLA (`jit_compile=True`). XLA mengompilasi graph menjadi kernel yang menyatu. Ia sering direkomendasikan tanpa syarat; kasus ini mengukurnya alih-alih mempercayainya.

9. Mixed precision bf16. Compute capability 8.6 punya Tensor Core bf16. Kasus ini mengukur perolehannya terhadap fp32 pada CNN dan transformer. Hanya dijalankan di GPU: di CPU, bf16 diemulasi dan justru lebih lambat, sehingga perbandingannya tidak bermakna.

Hasil pengukuran

GEMM fp32 (GFLOP/s)



Gambar 1: Atas: throughput training pada model.fit. Tengah: titik potong CPU/GPU terhadap ukuran batch. ⁶ Bawah: speedup inference terhadap

Ukuran	CPU	GPU	Speedup
1024x1024	241	1,489	6.2x
2048x2048	370	4,545	12.3x
4096x4096	398	3,647	9.2x

Speedup naik seiring ukuran matriks. Pada matriks kecil, GPU belum terisi penuh dan biaya peluncuran kernel masih terasa; pada matriks besar barulah throughput aritmetikanya terlihat utuh. Pola ini akan berulang di setiap kasus berikutnya.

Titik potong: throughput vs ukuran batch

Batch	CPU ms	GPU ms	CPU spl/s	GPU spl/s	Speedup
128	10.2	8.9	12,581	14,308	1.1x
512	20.5	10.2	24,998	50,109	2.0x
2048	48.7	14.3	42,046	142,721	3.4x
8192	175.5	34.2	46,665	239,266	5.1x

Perhatikan kolom milidetik, bukan kolom speedup. Waktu per langkah di CPU naik hampir sebanding dengan besar batch — itu komputasi nyata. Di GPU, waktu per langkah nyaris tidak bergerak pada batch kecil (8.9 ms pada batch 128) lalu baru naik pada batch besar. Bagian yang datar itulah biaya tetap: sekitar 9 ms yang dibayar setiap langkah terlepas dari berapa banyak pekerjaan yang diberikan.

Di mesin ini biaya tetap tersebut besar karena WSL hanya memaparkan 3 core. Host-lah yang menyusun dan meluncurkan kernel; dengan CPU sesempit itu, GPU sering menganggur menunggu diberi pekerjaan. Implikasi praktisnya: **perbesar batch sampai VRAM hampir penuh**. Pada perangkat 8 GB ini, batch yang terlalu kecil membuang kapasitas GPU secara percuma.

Overhead `model.fit` (sampel/detik)

steps_per_execution	CPU	GPU	GPU/CPU
1	10,638	9,473	0.9x
32	12,890	16,286	1.3x

Menaikkan `steps_per_execution` dari 1 ke 32 memberi **1.7x** di GPU tanpa mengubah model, data, atau hyperparameter apa pun — cukup satu argumen

tambahan pada `model.compile`. Perolehan ini datang dari menghilangkan perjalanan bolak-balik Python dan sinkronisasi device di setiap langkah. Semakin kecil modelnya, semakin besar perolehannya. Di CPU efeknya kecil, karena di sana tidak ada sinkronisasi device yang perlu diamortisasi.

Training penuh (`model.fit`, detik per epoch)

Model	Param	CPU s/ep	GPU s/ep	Speedup
MLP	1.5M	5.6	6.6	0.8x
CNN	0.3M	13.0	13.0	1.0x
Transformer	8.3M	55.0	13.7	4.0x

Urutan perolehan GPU pada pengukuran ini: Transformer (4.0x), CNN (1.0x), MLP (0.8x).

Mekanismenya sama di ketiganya, hanya bobotnya berbeda. Yang menentukan adalah berapa banyak pekerjaan aritmetika yang dikerjakan per peluncuran kernel. Transformer memberi paling banyak: *attention* dan lapisan *feed-forward* adalah matmul besar, dan model ini yang terbesar parameternya. MLP memberi paling sedikit: langkahnya terlalu pendek, sehingga biaya tetap per langkah menelan sebagian besar waktunya. CNN berada di antaranya, dan hasilnya lebih rendah dari yang biasa diperkirakan orang untuk konvolusi — sebabnya ada pada `BatchNormalization`.

Pengukuran terpisah pada satu langkah training CNN menunjukkan lapisan normalisasi itu sendiri menyumbang sekitar 51 ms dari 90 ms per langkah di GPU. Di backend TensorFlow, `BatchNormalization` Keras 3 tidak dipetakan ke kernel cuDNN yang menyatu; ia tersusun dari banyak operasi kecil, dan setiap operasi kecil membayar ongkos peluncuran. Dengan 3 core di WSL yang harus menyusun peluncuran itu, ongkosnya membengkak. Ini kembali ke tema yang sama: pada perangkat ini, yang membatasi sering kali bukan GPU-nya, melainkan host yang memberinya makan.

Angka pada tabel ini memakai `steps_per_execution=1`, default Keras, sehingga mewakili apa yang dialami pengguna apa adanya — bukan hasil yang sudah disetel.

XLA `jit_compile` pada CNN (sampel/detik)

XLA	CPU	GPU	GPU/CPU
nonaktif	760	1,089	1.4x
aktif	463	743	1.6x

Pada model dan perangkat ini, mengaktifkan XLA **justru memperlambat** training GPU (1,089 menjadi 743 sampel/detik, 0.7x). Hasil ini layak digarisbawahi karena bertentangan dengan saran yang umum beredar. XLA menyatukan operasi-operasi kecil — yang mestinya menolong, mengingat diagnosis di atas — tetapi ia juga menggantikan pemilihan algoritma konvolusi milik cuDNN dengan pilihannya sendiri, dan untuk konvolusi 3x3 pada citra kecil pilihan itu bisa lebih buruk. Ditambah waktu kompilasi yang harus dibayar di awal.

Kesimpulannya bukan “jangan pakai XLA”, melainkan **ukur XLA pada model Anda sendiri sebelum memakainya**. Ia bisa memberi perolehan besar pada model yang didominasi operasi *pointwise*, dan kerugian seperti di sini pada model yang didominasi konvolusi.

Inference: latensi vs throughput

cnn (ms per batch, dan sampel/detik)

Batch	CPU ms	GPU ms	CPU spl/s	GPU spl/s	Speedup
1	3.97	2.80	252	358	1.4x
8	7.73	3.85	1,035	2,076	2.0x
64	22.01	7.15	2,908	8,946	3.1x
512	139.83	57.60	3,662	8,889	2.4x

transformer (ms per batch, dan sampel/detik)

Batch	CPU ms	GPU ms	CPU spl/s	GPU spl/s	Speedup
1	17.29	7.61	58	132	2.3x
8	55.23	19.89	145	402	2.8x
64	280.71	139.67	228	458	2.0x
512	2255.19	989.40	227	518	2.3x

Dua kolom terakhir menceritakan hal yang berbeda, dan keduanya penting.

Kolom milidetik adalah **latensi**: berapa lama satu permintaan ditunggu. Pada batch 1, GPU nyaris tidak memberi keuntungan — pekerjaannya terlalu sedikit

untuk menutupi ongkos mengirim data ke VRAM, meluncurkan kernel, dan menarik hasilnya kembali. Untuk layanan yang melayani satu permintaan pada satu waktu dengan target latensi ketat, CPU sering merupakan pilihan yang benar, dan sekaligus lebih murah dan lebih sederhana untuk dioperasikan.

Kolom sampel/detik adalah **throughput**: berapa banyak yang selesai per satuan waktu. Di sini GPU menang telak pada batch besar. Untuk pekerjaan *batch* — memberi label satu korpus, mengekstrak *embedding*, mengevaluasi himpunan uji — GPU jelas alat yang tepat.

Aturan praktisnya: kalau permintaan datang satu per satu dan pengguna menunggu, ukur latensi. Kalau pekerjaan bisa dikumpulkan dulu, ukur throughput dan perbesar batch.

Mixed precision bf16 (GPU saja, sampel/detik)

Model	fp32	bf16	Speedup	VRAM puncak fp32/bf16 (MB)
cnn	768	639	0.8x	390.7 / 306.2
transformer	293	491	1.7x	497.3 / 402.1

bf16 punya rentang eksponen yang sama dengan fp32, hanya mantisanya lebih pendek. Karena itu ia tidak memerlukan *loss scaling* seperti fp16, dan pada Ampere praktis selalu layak dipakai untuk training. Perolehan kecepatannya nyata tetapi biasanya lebih sederhana daripada yang dijanjikan angka Tensor Core — sebab sebagian beban kerja terbatas oleh bandwidth memori, bukan aritmetika. Penghematan VRAM-nya sering justru lebih berharga daripada kecepatannya: pada perangkat 8 GB, VRAM yang bebas bisa ditukar dengan batch yang lebih besar, dan batch lebih besar itulah yang mengembalikan kecepatan.

Tabel gabungan

Kasus	Konfigurasi	Satuan	CPU	GPU	Speedup
GEMM	1024x1024 fp32	GFLOP/s	241.4	1488.9	6.2x
GEMM	2048x2048 fp32	GFLOP/s	370.5	4545.2	12.3x
GEMM	4096x4096 fp32	GFLOP/s	398.0	3646.6	9.2x

Kasus	Konfigurasi	Satuan	CPU	GPU	Speedup
Skala batch (MLP)	batch 128	sampel/s	12581	14308	1.1x
Skala batch (MLP)	batch 512	sampel/s	24998	50109	2.0x
Skala batch (MLP)	batch 2048	sampel/s	42046	142721	3.4x
Skala batch (MLP)	batch 8192	sampel/s	46665	239266	5.1x
Overhead fit	steps_per_execution=1	sampel/s	10638	9473	0.9x
Overhead fit	steps_per_execution=32	sampel/s	12890	16286	1.3x
XLA (CNN)	jit_compile=False	sampel/s	760	1089	1.4x
XLA (CNN)	jit_compile=True	sampel/s	463	743	1.6x
Training MLP	batch 128, 1.5M param	sampel/s	10752.1	9056.5	0.8x
Training CNN	batch 128, 0.3M param	sampel/s	768.7	768.5	1.0x
Training Transformer	batch 32, 8.3M param	sampel/s	72.7	292.9	4.0x
Inference cnn	batch 1	ms/batch	3.974	2.796	1.4x
Inference cnn	batch 8	ms/batch	7.727	3.854	2.0x
Inference cnn	batch 64	ms/batch	22.009	7.154	3.1x
Inference cnn	batch 512	ms/batch	139.828	57.600	2.4x
Inference transformer	batch 1	ms/batch	17.288	7.607	2.3x
Inference transformer	batch 8	ms/batch	55.231	19.885	2.8x
Inference transformer	batch 64	ms/batch	280.711	139.671	2.0x
Inference transformer	batch 512	ms/batch	2255.188	989.401	2.3x
bf16 vs fp32 (cnn)	GPU saja	sampel/s	768.5 (fp32)	638.7 (bf16)	0.8x
bf16 vs fp32 (transformer)	GPU saja	sampel/s	292.9 (fp32)	490.9 (bf16)	1.7x

Kapan memakai CPU, kapan GPU

Hasil di atas bisa diringkas menjadi keputusan yang cukup jelas.

Pakai GPU untuk: training model apa pun yang punya konvolusi atau *attention*; training apa pun yang berjalan lebih dari beberapa menit; inference *batch* atas banyak data; dan setiap eksperimen yang ingin Anda ulang beberapa kali dengan seed berbeda. Di kategori ini selisihnya bukan soal persentase, melainkan soal apakah eksperimennya selesai hari ini atau minggu depan.

Pakai CPU untuk: inference satu-per-satu dengan target latensi ketat; model klasik (SVM, gradient boosting, regresi logistik) yang memang tidak

dirancang untuk GPU; prapemrosesan dan tokenisasi; dan pengembangan awal ketika Anda hanya ingin tahu apakah kodenya jalan. Memindahkan model 200 MB ke VRAM untuk mengklasifikasi satu kalimat adalah kerugian bersih.

Yang perlu diwaspadai adalah wilayah abu-abu di bawah batch 128. Di sana GPU sedang menganggur menunggu diberi pekerjaan, dan menambah GPU tidak akan menyelesaikan apa pun. Kalau training Anda terasa lambat di wilayah ini, urutan perbaikannya:

1. **Perbesar batch** sampai VRAM hampir penuh. Ini pengungkit terbesar dan paling murah.
2. **Naikkan `steps_per_execution`** pada `model.compile`, misalnya ke 32. Satu argumen, tanpa risiko terhadap hasil.
3. **Aktifkan `mixed precision bf16`** dengan `keras.mixed_precision.set_global_policy('mixed_float16')`. Aman di Ampere, dan VRAM yang dihemat bisa ditukar dengan batch yang lebih besar lagi.
4. **Periksa `pipeline data`**. Dengan 3 core di WSL, pemuatan dan augmentasi data gampang menjadi hambatan sesungguhnya. Gunakan `tf.data` dengan `.cache()` dan `.prefetch(tf.data.AUTOTUNE)`, dan jaga jumlah worker di kisaran 2-4.
5. **Baru setelah itu** pertimbangkan `jit_compile=True` (XLA). Ia bisa membantu banyak, tetapi juga bisa memperpanjang waktu kompilasi dan sesekali gagal pada model dinamis — jadi ukur, jangan asumsikan.

Satu catatan tentang perangkat ini secara khusus: **8 GB VRAM adalah batasan yang mengikat, dan 3 core CPU di WSL adalah batasan kedua yang sering terlupakan.** Yang pertama membatasi seberapa besar model yang muat; yang kedua membatasi seberapa cepat Anda bisa memberinya makan. Menaikkan alokasi memori WSL lewat `%UserProfile%\wslconfig` (`memory=24GB`, dan `processors=8` bila tersedia) sering memberi perbaikan yang lebih besar daripada tuning model.

Kaitan dengan rencana riset

Bila arah pemakaiannya adalah *fine-tuning* encoder untuk klasifikasi ambiguitas persyaratan — DeBERTa-v3-base atau IndoBERT pada kalimat pendek — hasil di atas memberi beberapa konsekuensi langsung.

Kasus transformer dalam laporan ini adalah versi mininya: encoder-only, sekuens 128 token, hanya lebih kecil dari model 183 juta parameter yang sesungguhnya. Rasio CPU-GPU yang terukur di sini akan bertahan dan bahkan melebar untuk model yang lebih besar, karena model besar memberi lebih banyak pekerjaan per langkah sehingga biaya tetap semakin tidak relevan.

Dalam praktiknya: dengan `max_length=128` dan batch 32 dalam bf16, DeBERTa-v3-base memakai sekitar 2-4 GB VRAM dan satu putaran *fine-tuning* penuh selesai dalam hitungan menit. Itu artinya validasi silang 5-lipat dengan beberapa seed sangat terjangkau di perangkat ini — dan untuk kumpulan data ambiguitas yang biasanya hanya beberapa ratus sampai beberapa ribu kalimat, pengulangan itu jauh lebih menentukan kekuatan klaim Anda daripada memilih model yang lebih besar.

Tiga hal yang perlu diantisipasi:

Pertama, **dataset kecil membuat langkah training pendek**, dan langkah pendek adalah wilayah tempat GPU paling tidak efisien. Perbesar batch dan naikan `steps_per_execution`; jangan menyimpulkan bahwa GPU-nya bermasalah.

Kedua, **tokenisasi berjalan di CPU**, dan CPU Anda hanya 3 core di WSL. Lakukan tokenisasi sekali di awal lalu simpan hasilnya, jangan mengulanginya setiap epoch.

Ketiga, **untuk inference saat demo atau saat menyajikan model**, ukur latensi batch 1 seperti pada kasus 7 sebelum berasumsi bahwa GPU diperlukan. Untuk mengklasifikasi satu kalimat persyaratan, CPU kemungkinan besar sudah cukup, dan itu menyederhanakan penyajiannya secara signifikan.

Cara menjalankan ulang

```
# semua kasus, kedua device (perlu belasan menit)
python cpu_vs_gpu.py --preset standard --report results

# versi cepat untuk memastikan semuanya jalan
python cpu_vs_gpu.py --preset quick

# hanya kasus tertentu
python cpu_vs_gpu.py --only gemm,scaling,inference
```

```
# bangun ulang PDF ini dari hasil terbaru
python make_report.py
```

Keluarannya: results/cpu.json, results/gpu.json, results/summary.json (berisi seluruh angka mentah termasuk min dan p90 untuk memeriksa kestabilan), serta results/cpu_vs_gpu.png.

Bila hasil Anda berbeda jauh dari laporan ini, periksa dulu: apakah mesin sedang panas, apakah ada proses lain memakai GPU (nvidia-smi), dan berapa banyak RAM yang tersisa di WSL (free -h). Ketiganya bisa menggeser angka secara substansial.

Lampiran: kode lengkap

Berkas cpu_vs_gpu.py, ditulis dengan Keras 3 di atas backend TensorFlow.

```
"""
```

*Benchmark CPU vs GPU (CUDA) untuk beban kerja AI: training dan inference.
Ditulis dengan Keras 3 (backend TensorFlow).*

Disesuaikan untuk perangkat pada check_gpu/gpu_spec.md:

*GPU : RTX 3070 Ti Laptop, 8 GB VRAM, compute 8.6 (Ampere) -> bf16 + TF32, tanpa FP8
CPU : i9-12900H, hanya 6 logical / 3 core yang terlihat di WSL
RAM : 19 GiB total (~6 GiB bebas), swap 8 GiB*

Semua kasus uji dibatasi agar muat di <4 GB VRAM dan <3 GB RAM, sehingga sisi CPU tetap selesai dalam waktu yang wajar meski hanya punya 3 core.

Cara pakai

<code>python cpu_vs_gpu.py</code>	<code># jalankan semua kasus di CPU lalu GPU</code>
<code>python cpu_vs_gpu.py --preset quick</code>	<code># versi cepat (~2-3 menit)</code>
<code>python cpu_vs_gpu.py --preset full</code>	<code># versi panjang, angka paling stabil</code>
<code>python cpu_vs_gpu.py --only gemm,cnn</code>	<code># pilih kasus tertentu</code>
<code>python cpu_vs_gpu.py --device gpu</code>	<code># satu device saja</code>
<code>python cpu_vs_gpu.py --report hasil/</code>	<code># tulis JSON + PNG ke folder lain</code>

Catatan metodologi (ini yang membuat angkanya layak dikutip)

1. CPU dan GPU dijalankan di *proses terpisah*. TensorFlow menempatkan op ke GPU sejak inisialisasi, jadi ``with tf.device('/CPU:0')`` di proses yang sama masih bocor ke GPU. Proses anak untuk CPU dijalankan dengan `CUDA_VISIBLE_DEVICES=-1`.
2. Setiap pengukuran didahului warm-up yang dibuang: iterasi pertama berisi `tracing tf.function`, `autotune cuDNN`, dan alokasi memori -- bukan biaya komputasi.
3. Eksekusi GPU bersifat asinkron. Timer selalu ditutup dengan sinkronisasi device eksplisit, kalau tidak yang terukur hanyalah kecepatan Python melempar kernel.
4. Yang dilaporkan adalah median, bukan rata-rata: satu iterasi yang kena thermal throttling atau scheduler WSL tidak boleh menggeser hasil.
5. Data dibangkitkan secara sintetis dengan seed tetap. Untuk mengukur *waktu*,

isi data tidak berpengaruh -- yang penting bentuk tensor dan jumlah operasinya identik di kedua device, dan tidak ada dependensi unduhan dataset.

"""

```
from __future__ import annotations
```

```
import argparse
```

```
import json
```

```
import os
```

```
import platform
```

```
import statistics
```

```
import subprocess
```

```
import sys
```

```
import time
```

```
from pathlib import Path
```

```
# -----
```

```
# Preset ukuran beban kerja
```

```
# -----
```

```
PRESETS = {
```

```
    "quick": {
```

```
        "gemm_sizes": [1024, 2048],
```

```
        "gemm_iters": 10,
```

```
        "mlp_samples": 20_000,
```

```
        "mlp_epochs": 2,
```

```
        "cnn_samples": 5_000,
```

```
        "cnn_epochs": 1,
```

```
        "trf_samples": 2_000,
```

```
        "trf_epochs": 1,
```

```
        "infer_batches": [1, 32, 256],
```

```
        "infer_iters": 30,
```

```
        "scaling_batches": [128, 1024, 4096],
```

```
    },
```

```
    "standard": {
```

```
        "gemm_sizes": [1024, 2048, 4096],
```

```
        "gemm_iters": 20,
```

```
        "mlp_samples": 60_000,
```

```
        "mlp_epochs": 3,
```

```
        "cnn_samples": 10_000,
```

```
        "cnn_epochs": 2,
```

```
        "trf_samples": 4_000,
```

```
        "trf_epochs": 1,
```

```
        "infer_batches": [1, 8, 64, 512],
```

```
        "infer_iters": 50,
```

```
        "scaling_batches": [128, 512, 2048, 8192],
```

```
    },
```

```
    "full": {
```

```
        "gemm_sizes": [1024, 2048, 4096, 8192],
```

```
        "gemm_iters": 30,
```

```
        "mlp_samples": 60_000,
```

```
        "mlp_epochs": 5,
```

```

        "cnn_samples": 20_000,
        "cnn_epochs": 3,
        "trf_samples": 8_000,
        "trf_epochs": 2,
        "infer_batches": [1, 8, 64, 512, 1024],
        "infer_iters": 100,
        "scaling_batches": [128, 512, 2048, 8192, 16384],
    },
}

ALL_CASES = ["gemm", "scaling", "overhead", "xla", "mlp", "cnn", "transformer",
             "inference", "bf16"]

SEED = 1337
MLP_BATCH = 128
CNN_BATCH = 128
TRF_BATCH = 32

# Hyperparameter transformer encoder kecil -- sengaja dibuat mirip bentuk beban
# kerja klasifikasi kalimat (seq pendek, encoder-only), bukan LLM generatif.
TRF_VOCAB = 20_000
TRF_SEQLEN = 128
TRF_DMODEL = 256
TRF_HEADS = 4
TRF_LAYERS = 4
TRF_FF = 1024
N_CLASSES = 10

# -----
# Utilitas timing
# -----

def sync_device():
    """Blokir sampai semua kernel yang antre di device selesai.

    Wajib sebelum menutup timer: eksekusi GPU asinkron, tanpa ini yang terukur
    adalah waktu enqueue, bukan waktu komputasi.
    """
    import tensorflow as tf

    if hasattr(tf.test.experimental, "sync_devices"):
        tf.test.experimental.sync_devices()
    else: # fallback: paksa transfer device->host
        tf.constant(0.0).numpy()

def timed_median(fn, iters, warmup=3):
    """Jalankan fn() beberapa kali, buang warm-up, kembalikan statistik detik."""
    for _ in range(warmup):
        fn()
    sync_device()

```

```

samples = []
for _ in range(iters):
    t0 = time.perf_counter()
    fn()
    sync_device()
    samples.append(time.perf_counter() - t0)

samples.sort()
return {
    "median_s": statistics.median(samples),
    "min_s": samples[0],
    "p90_s": samples[min(len(samples) - 1, int(0.9 * len(samples)))],
    "iters": iters,
}

def peak_vram_mb():
    import tensorflow as tf

    try:
        info = tf.config.experimental.get_memory_info("GPU:0")
        return round(info["peak"] / 1024**2, 1)
    except Exception:
        return None

def reset_vram_stats():
    import tensorflow as tf

    try:
        tf.config.experimental.reset_memory_stats("GPU:0")
    except Exception:
        pass

# -----
# Data sintetis
# -----

def make_tabular(n, dim):
    import numpy as np

    rng = np.random.default_rng(SEED)
    x = rng.standard_normal((n, dim), dtype=np.float32)
    y = rng.integers(0, N_CLASSES, size=n).astype("int32")
    return x, y

def make_images(n):
    import numpy as np

```

```

rng = np.random.default_rng(SEED)
x = rng.random((n, 32, 32, 3), dtype=np.float32)
y = rng.integers(0, N_CLASSES, size=n).astype("int32")
return x, y

def make_tokens(n):
    import numpy as np

    rng = np.random.default_rng(SEED)
    x = rng.integers(0, TRF_VOCAB, size=(n, TRF_SEQLEN)).astype("int32")
    y = rng.integers(0, N_CLASSES, size=n).astype("int32")
    return x, y

# -----
# Model
# -----

def build_mlp():
    import keras

    return keras.Sequential(
        [
            keras.Input(shape=(784,)),
            keras.layers.Dense(1024, activation="relu"),
            keras.layers.Dense(512, activation="relu"),
            keras.layers.Dense(256, activation="relu"),
            keras.layers.Dense(N_CLASSES, activation="softmax", dtype="float32"),
        ],
        name="mlp",
    )

def build_cnn():
    import keras

    L = keras.layers

    def block(x, filters):
        for _ in range(2):
            x = L.Conv2D(filters, 3, padding="same", use_bias=False)(x)
            x = L.BatchNormalization()(x)
            x = L.Activation("relu")(x)
        return L.MaxPooling2D()(x)

    inp = keras.Input(shape=(32, 32, 3))
    x = block(inp, 32)
    x = block(x, 64)
    x = block(x, 128)
    x = L.GlobalAveragePooling2D()(x)
    x = L.Dense(256, activation="relu")(x)

```

```

out = L.Dense(N_CLASSES, activation="softmax", dtype="float32")(x)
return keras.Model(inp, out, name="cnn")

def build_transformer():
    import keras
    import tensorflow as tf

    L = keras.layers
    inp = keras.Input(shape=(TRF_SEQLEN,), dtype="int32")

    tok = L.Embedding(TRF_VOCAB, TRF_DMODEL)(inp)
    pos = L.Embedding(TRF_SEQLEN, TRF_DMODEL)(tf.range(TRF_SEQLEN))
    x = tok + pos

    for _ in range(TRF_LAYERS):
        attn = L.MultiHeadAttention(num_heads=TRF_HEADS, key_dim=TRF_DMODEL // TRF_HEADS)(x, x)
        x = L.LayerNormalization(epsilon=1e-6)(x + attn)
        ff = L.Dense(TRF_FF, activation="gelu")(x)
        ff = L.Dense(TRF_DMODEL)(ff)
        x = L.LayerNormalization(epsilon=1e-6)(x + ff)

    x = L.GlobalAveragePooling1D()(x)
    out = L.Dense(N_CLASSES, activation="softmax", dtype="float32")(x)
    return keras.Model(inp, out, name="transformer_encoder")

def compile_model(model, steps_per_execution=1):
    """steps_per_execution=1 adalah default Keras: setiap step kembali ke Python
    dan menyinkronkan device. Menaikkannya mengamortisasi overhead itu -- lihat
    kasus `overhead`."""
    model.compile(
        optimizer="adam",
        loss="sparse_categorical_crossentropy",
        metrics=[],
        steps_per_execution=steps_per_execution,
    )
    return model

# -----
# Kasus uji
# -----

def case_gemm(cfg, log):
    """Microbenchmark GEMM: batas atas throughput aritmetika device.

    Perkalian matriks  $N \times N$  butuh  $2N^3$  FLOP. Ini kasus paling menguntungkan GPU
    (compute-bound, akses memori teratur) sehingga berguna sebagai plafon: tidak
    ada beban kerja nyata yang speedup-nya melebihi angka di sini.
    """
    import tensorflow as tf

```

```

results = []
for n in cfg["gemm_sizes"]:
    a = tf.random.normal((n, n), dtype=tf.float32)
    b = tf.random.normal((n, n), dtype=tf.float32)

    @tf.function(reduce_retracing=True)
    def step():
        return tf.matmul(a, b)

    iters = max(3, cfg["gemm_iters"] // (1 + n // 2048))
    stat = timed_median(step, iters, warmup=2)
    gflops = (2.0 * n**3) / stat["median_s"] / 1e9
    log(f"  GEMM {n}x{n}: {stat['median_s']*1e3:8.2f} ms   {gflops:8.1f} Gflop/s")
    results.append({"n": n, "gflops": round(gflops, 1), **stat})

del a, b

return {"case": "gemm", "unit": "Gflop/s", "runs": results}

def _train_case(name, model, x, y, batch, epochs, log):
    """Ukur waktu training per epoch dengan model.fit.

    Satu epoch warm-up dijalankan pada potongan kecil terlebih dahulu supaya biaya
    tracing graph dan autotune cuDNN tidak masuk ke hasil.
    """
    reset_vram_stats()
    model.fit(x[: batch * 3], y[: batch * 3], batch_size=batch, epochs=1, verbose=0)
    sync_device()

    t0 = time.perf_counter()
    model.fit(x, y, batch_size=batch, epochs=epochs, verbose=0, shuffle=False)
    sync_device()
    total = time.perf_counter() - t0

    per_epoch = total / epochs
    samples_s = len(x) / per_epoch
    steps = -(-len(x) // batch)
    log(
        f"  {name}: {per_epoch:7.2f} s/epoch   {samples_s:9.1f} sampel/s    "
        f"{per_epoch / steps * 1e3:7.2f} ms/step"
    )
    return {
        "case": name,
        "unit": "sampel/s",
        "params": int(model.count_params()),
        "samples": len(x),
        "batch": batch,
        "epochs": epochs,
        "s_per_epoch": round(per_epoch, 3),
        "samples_per_s": round(samples_s, 1),
    }

```

```

    "ms_per_step": round(per_epoch / steps * 1e3, 3),
    "peak_vram_mb": peak_vram_mb(),
}

```

```
def case_scaling(cfg, log):
```

```

    """Sapuan ukuran batch pada satu langkah training MLP (tf.function murni).

```

```

    Ini kasus paling penting untuk perangkat ini. GPU punya biaya tetap per step
    -- peluncuran kernel, sinkronisasi, dan dispatch dari Python -- yang di WSL
    dengan 3 core terasa besar. Biaya itu tidak bergantung ukuran batch, sedangkan
    waktu komputasi CPU naik linear. Jadi ada titik potong: di bawahnya GPU kalah,
    di atasnya GPU menang, dan jaraknya melebar terus. Grafik dari kasus ini
    menjawab pertanyaan "kenapa GPU saya tidak terasa lebih cepat?".
    """

```

```

import keras
import tensorflow as tf

```

```

model = build_mlp()
optimizer = keras.optimizers.Adam()
loss_fn = keras.losses.SparseCategoricalCrossentropy()

```

```
@tf.function(reduce_retracing=True)
```

```
def train_step(xb, yb):
```

```

    with tf.GradientTape() as tape:
        loss = loss_fn(yb, model(xb, training=True))
        grads = tape.gradient(loss, model.trainable_variables)
        optimizer.apply_gradients(zip(grads, model.trainable_variables))
    return loss

```

```
runs = []
```

```
for b in cfg["scaling_batches"]:
```

```

    xb, yb = make_tabular(b, 784)
    xb, yb = tf.constant(xb), tf.constant(yb)
    reset_vram_stats()
    iters = max(5, cfg["gemm_iters"])
    stat = timed_median(lambda a=xb, c=yb: train_step(a, c), iters, warmup=5)
    ms = stat["median_s"] * 1e3
    log(f"  batch={b:<6d} {ms:8.3f} ms/step    {b / stat['median_s']:10.0f} sampel/s")
    runs.append({
        "batch": b,
        "ms_per_step": round(ms, 4),
        "samples_per_s": round(b / stat["median_s"], 1),
        "peak_vram_mb": peak_vram_mb(),
    })
del xb, yb

```

```

return {"case": "scaling", "unit": "sampel/s", "params": int(model.count_params()),
        "runs": runs}

```

```
def case_overhead(cfg, log):
```

```
"""Efek `steps_per_execution` pada model.fit.
```

Default Keras adalah 1: tiap step kembali ke Python dan menyinkronkan device untuk agregasi loss. Pada GPU ongkos itu bisa melebihi komputasinya sendiri. Menaikkan ke 32 membuat 32 step dijalankan dalam satu panggilan graph. Ini optimasi satu baris yang sering terlewat.

```
"""
```

```
x, y = make_tabular(cfg["mlp_samples"], 784)
runs = []
for spe in (1, 32):
    model = compile_model(build_mlp(), steps_per_execution=spe)
    r = _train_case(f"mlp_fit_spe{spe}", model, x, y, MLP_BATCH, cfg["mlp_epochs"], log)
    r["steps_per_execution"] = spe
    runs.append(r)
    del model
return {"case": "overhead", "unit": "sampel/s", "runs": runs}
```

```
def case_xla(cfg, log):
```

```
    """Efek jit_compile=True (XLA) pada training CNN.
```

XLA sering direkomendasikan begitu saja. Kasus ini mengukurnya alih-alih mengasumsikannya: XLA mengompilasi ulang graph menjadi kernel yang menyatu, yang menolong bila beban kerja didominasi banyak op kecil, tetapi menambah waktu kompilasi dan bisa memilih kernel konvolusi yang lebih lambat daripada pilihan cuDNN. Hasilnya perlu diverifikasi per model dan per perangkat.

```
"""
```

```
x, y = make_images(cfg["cnn_samples"])
runs = []
for jit in (False, True):
    model = build_cnn()
    model.compile(optimizer="adam", loss="sparse_categorical_crossentropy",
                  metrics=[], steps_per_execution=32, jit_compile=jit)
    r = _train_case(f"cnn_fit_xla{int(jit)}", model, x, y, CNN_BATCH,
                  cfg["cnn_epochs"], log)
    r["jit_compile"] = jit
    runs.append(r)
    del model
return {"case": "xla", "unit": "sampel/s", "runs": runs}
```

```
def case_mlp(cfg, log):
```

```
    """Training MLP dense. Kecil, murni matmul, tanpa conv -- speedup GPU nyata
    tapi moderat karena tiap step terlalu pendek untuk menutupi overhead launch."""
```

```
x, y = make_tabular(cfg["mlp_samples"], 784)
model = compile_model(build_mlp())
return _train_case("mlp_train", model, x, y, MLP_BATCH, cfg["mlp_epochs"], log)
```

```
def case_cnn(cfg, log):
```

```
    """Training CNN pada citra 32x32. Konvolusi adalah beban kerja yang paling
    diuntungkan cuDNN + Tensor Core; di sinilah selisih CPU-GPU paling ekstrem."""
```

```

x, y = make_images(cfg["cnn_samples"])
model = compile_model(build_cnn())
return _train_case("cnn_train", model, x, y, CNN_BATCH, cfg["cnn_epochs"], log)

def case_transformer(cfg, log):
    """Training encoder transformer kecil (seq 128). Bentuk beban kerjanya sama
    dengan fine-tuning BERT/DeBERTa untuk klasifikasi kalimat, hanya lebih kecil."""
    x, y = make_tokens(cfg["trf_samples"])
    model = compile_model(build_transformer())
    return _train_case("transformer_train", model, x, y, TRF_BATCH, cfg["trf_epochs"], log)

def case_inference(cfg, log):
    """Inference murni (forward pass) pada beberapa ukuran batch.

    Ini kasus yang paling sering disalahpahami. Pada batch 1 GPU sering kalah atau
    hanya imbang: waktunya didominasi latensi peluncuran kernel dan transfer
    host<->device, bukan komputasi. Keunggulan GPU baru muncul saat batch besar,
    ketika 46 SM benar-benar terisi penuh.
    """
    import tensorflow as tf

    out = {"case": "inference", "unit": "ms/batch", "models": {}}

    for label, builder, maker in (
        ("cnn", build_cnn, make_images),
        ("transformer", build_transformer, make_tokens),
    ):
        model = builder()
        max_b = max(cfg["infer_batches"])
        x, _ = maker(max_b)

        @tf.function(reduce_retracing=True)
        def forward(batch):
            return model(batch, training=False)

        runs = []
        for b in cfg["infer_batches"]:
            xb = tf.constant(x[:b])
            reset_vram_stats()
            stat = timed_median(lambda: forward(xb), cfg["infer_iters"], warmup=5)
            lat_ms = stat["median_s"] * 1e3
            thr = b / stat["median_s"]
            log(
                f" {label} infer batch={b:<5d} {lat_ms:8.3f} ms/batch "
                f"{thr:10.1f} sampel/s"
            )
            runs.append(
                {
                    "batch": b,
                    "latency_ms": round(lat_ms, 4),
                }
            )

```

```

        "throughput_samples_s": round(thr, 1),
        "peak_vram_mb": peak_vram_mb(),
    }
)
del xb

out["models"][label] = {"params": int(model.count_params()), "runs": runs}
del model, x

return out

def case_bf16(cfg, log, on_gpu):
    """Training CNN + transformer dengan mixed precision bf16.

    Hanya bermakna di GPU: compute 8.6 punya Tensor Core bf16. Di CPU bf16
    diemulasikan dan justru lebih lambat, jadi kasus ini dilewati di sisi CPU.
    Dibandingkan terhadap hasil fp32 dari kasus cnn/transformer.
    """
    if not on_gpu:
        log(" dilewati: bf16 hanya diukur di GPU (di CPU bf16 diemulasi, bukan dipercepat)")
        return {"case": "bf16", "skipped": "cpu"}

import keras

keras.mixed_precision.set_global_policy("mixed_bfloat16")
try:
    xi, yi = make_images(cfg["cnn_samples"])
    r_cnn = _train_case("cnn_train_bf16", compile_model(build_cnn()), xi, yi,
                       CNN_BATCH, cfg["cnn_epochs"], log)
    del xi, yi

    xt, yt = make_tokens(cfg["trf_samples"])
    r_trf = _train_case("transformer_train_bf16", compile_model(build_transformer()),
                       xt, yt, TRF_BATCH, cfg["trf_epochs"], log)
finally:
    keras.mixed_precision.set_global_policy("float32")

return {"case": "bf16", "unit": "sampel/s", "runs": {"cnn": r_cnn, "transformer": r_trf}}

CASE_FN = {
    "gemm": case_gemm,
    "scaling": case_scaling,
    "overhead": case_overhead,
    "xla": case_xla,
    "mlp": case_mlp,
    "cnn": case_cnn,
    "transformer": case_transformer,
    "inference": case_inference,
    "bf16": case_bf16,
}

```

```

# -----
# Proses anak: menjalankan seluruh kasus pada SATU device
# -----

def run_child(device, cases, cfg, out_path):
    os.environ.setdefault("TF_CPP_MIN_LOG_LEVEL", "2")
    if device == "cpu":
        os.environ["CUDA_VISIBLE_DEVICES"] = "-1"

    import keras
    import tensorflow as tf

    keras.utils.set_random_seed(SEED)

    gpus = tf.config.list_physical_devices("GPU")
    on_gpu = bool(gpus)
    if device == "gpu" and not on_gpu:
        raise SystemExit("GPU diminta tetapi tidak terdeteksi TensorFlow.")
    if device == "cpu" and on_gpu:
        raise SystemExit("Isolasi CPU gagal: GPU masih terlihat oleh proses ini.")

    if on_gpu:
        # Tanpa ini TF mengambil seluruh VRAM di awal, sehingga peak memory
        # tidak terbaca dan proses lain di 8 GB yang sama ikut tercekik.
        for g in gpus:
            tf.config.experimental.set_memory_growth(g, True)

    def log(msg):
        print(msg, flush=True)

    header = {
        "device": device,
        "device_name": (
            tf.config.experimental.get_device_details(gpus[0]).get("device_name", "GPU")
            if on_gpu
            else platform.processor() or "CPU"
        ),
        "tf_version": tf.__version__,
        "keras_version": keras.__version__,
        "cpu_threads_visible": os.cpu_count(),
        "intra_op_threads": tf.config.threading.get_intra_op_parallelism_threads(),
        "tf32_enabled": bool(tf.config.experimental.tensor_float32_execution_enabled()),
    }

    log(f"\n=== DEVICE: {device.upper()} ({header['device_name']}) ===")

    results = {"meta": header, "cases": {}}
    for name in cases:
        log(f"\n[{device}] {name}")
        t0 = time.perf_counter()
        fn = CASE_FN[name]

```

```

    res = fn(cfg, log, on_gpu) if name == "bf16" else fn(cfg, log)
    res["wall_s"] = round(time.perf_counter() - t0, 2)
    results["cases"][name] = res

Path(out_path).write_text(json.dumps(results, indent=2))
log(f"\n[{device}] selesai -> {out_path}")

# -----
# Pelaporan
# -----

def fmt_speedup(gpu_val, cpu_val, higher_is_better=True):
    if not gpu_val or not cpu_val:
        return "-"
    ratio = gpu_val / cpu_val if higher_is_better else cpu_val / gpu_val
    return f"{ratio:.1f}x"

def build_report(cpu, gpu):
    """Kembalikan baris-baris tabel perbandingan (list of tuple)."""
    rows = []

    def c(name):
        return (cpu or {}).get("cases", {}).get(name)

    def g(name):
        return (gpu or {}).get("cases", {}).get(name)

    if c("gemm") and g("gemm"):
        cmap = {r["n"]: r["gflops"] for r in c("gemm")["runs"]}
        for r in g("gemm")["runs"]:
            n = r["n"]
            if n in cmap:
                rows.append(
                    ("GEMM", f"{n}x{n} fp32", "GFLOP/s",
                     f"{cmap[n]:.1f}", f"{r['gflops']:.1f}",
                     fmt_speedup(r["gflops"], cmap[n]))
                )

    if c("scaling") and g("scaling"):
        cmap = {r["batch"]: r for r in c("scaling")["runs"]}
        for r in g("scaling")["runs"]:
            b = r["batch"]
            if b in cmap:
                rows.append(
                    ("Skala batch (MLP)", f"batch {b}", "sampel/s",
                     f"{cmap[b]['samples_per_s']:.0f}", f"{r['samples_per_s']:.0f}",
                     fmt_speedup(r["samples_per_s"], cmap[b]["samples_per_s"]))
                )

    if c("overhead") and g("overhead"):

```

```

cmap = {r["steps_per_execution"]: r for r in c("overhead")["runs"]}
for r in g("overhead")["runs"]:
    spe = r["steps_per_execution"]
    if spe in cmap:
        rows.append(
            ("Overhead fit", f"steps_per_execution={spe}", "sampel/s",
             f"{cmap[spe]['samples_per_s']:.0f}", f"{r['samples_per_s']:.0f}",
             fmt_speedup(r["samples_per_s"], cmap[spe]["samples_per_s"]))
        )

if c("xla") and g("xla"):
    cmap = {r["jit_compile"]: r for r in c("xla")["runs"]}
    for r in g("xla")["runs"]:
        j = r["jit_compile"]
        if j in cmap:
            rows.append(
                ("XLA (CNN)", f"jit_compile={j}", "sampel/s",
                 f"{cmap[j]['samples_per_s']:.0f}", f"{r['samples_per_s']:.0f}",
                 fmt_speedup(r["samples_per_s"], cmap[j]["samples_per_s"]))
            )

for key, label in (("mlp", "Training MLP"), ("cnn", "Training CNN"),
                  ("transformer", "Training Transformer")):
    cc, gg = c(key), g(key)
    if cc and gg and "samples_per_s" in cc:
        rows.append(
            (label, f"batch {cc['batch']}, {cc['params']/1e6:.1f}M param", "sampel/s",
             f"{cc['samples_per_s']:.1f}", f"{gg['samples_per_s']:.1f}",
             fmt_speedup(gg["samples_per_s"], cc["samples_per_s"]))
        )

cc, gg = c("inference"), g("inference")
if cc and gg:
    for mname in cc.get("models", {}):
        if mname not in gg.get("models", {}):
            continue
        cmap = {r["batch"]: r for r in cc["models"][mname]["runs"]}
        for r in gg["models"][mname]["runs"]:
            b = r["batch"]
            if b not in cmap:
                continue
            rows.append(
                (f"Inference {mname}", f"batch {b}", "ms/batch",
                 f"{cmap[b]['latency_ms']:.3f}", f"{r['latency_ms']:.3f}",
                 fmt_speedup(r["latency_ms"], cmap[b]["latency_ms"], higher_is_better=False))
            )

gb = g("bf16")
if gb and "runs" in gb:
    for mname, run in gb["runs"].items():
        base = g(mname)
        if base and "samples_per_s" in base:

```

```

        rows.append(
            (f"bf16 vs fp32 ({mname})", "GPU saja", "sampel/s",
             f"{base['samples_per_s']:.1f} (fp32)",
             f"{run['samples_per_s']:.1f} (bf16)",
             fmt_speedup(run["samples_per_s"], base["samples_per_s"])))
    )

    return rows

def print_report(rows):
    if not rows:
        print("\nTidak ada pasangan hasil CPU+GPU untuk dibandingkan.")
        return
    head = ("Kasus", "Konfigurasi", "Satuan", "CPU", "GPU", "Speedup")
    widths = [max(len(str(r[i])) for r in [head, *rows]) for i in range(6)]
    line = " ".join("-" * w for w in widths)
    print("\n" + "=" * len(line))
    print("RINGKASAN CPU vs GPU")
    print("=" * len(line))
    print(" ".join(h.ljust(w) for h, w in zip(head, widths)))
    print(line)
    for r in rows:
        print(" ".join(str(v).ljust(w) for v, w in zip(r, widths)))
    print(line)
    print("Speedup > 1 berarti GPU lebih unggul. Untuk ms/batch, speedup dihitung "
          "sebagai CPU/GPU\nkarena pada satuan itu nilai yang lebih kecil lebih baik.")

def write_chart(cpu, gpu, path):
    try:
        import matplotlib

        matplotlib.use("Agg")
        import matplotlib.pyplot as plt
    except Exception as e:  # pragma: no cover
        print(f"(grafik dilewati: {e})")
        return None

    def case_of(src, name):
        return (src or {}).get("cases", {}).get(name)

    cinf, ginf = case_of(cpu, "inference"), case_of(gpu, "inference")
    cscl, gscl = case_of(cpu, "scaling"), case_of(gpu, "scaling")

    labels, cvals, gvals = [], [], []
    for key, lbl in (("mlp", "MLP"), ("cnn", "CNN"), ("transformer", "Transformer")):
        cc, gg = case_of(cpu, key), case_of(gpu, key)
        if cc and gg and "samples_per_s" in cc:
            labels.append(lbl)
            cvals.append(cc["samples_per_s"])
            gvals.append(gg["samples_per_s"])

```

```

panels = [bool(labels), bool(cscl and gscl), bool(cinf and ginf)]
ncols = sum(panels)
if ncols == 0:
    return None
fig, axes = plt.subplots(ncols, 1, figsize=(5.4, 3.1 * ncols), dpi=170)
axes = [axes] if ncols == 1 else list(axes)
ax_iter = iter(axes)

if labels:
    ax = next(ax_iter)
    idx = range(len(labels))
    ax.bar([i - 0.2 for i in idx], cvals, width=0.4, label="CPU", color="#7a8b99")
    ax.bar([i + 0.2 for i in idx], gvals, width=0.4, label="GPU", color="#3b7dd8")
    ax.set_xticks(list(idx))
    ax.set_xticklabels(labels)
    ax.set_yscale("log")
    ax.set_ylabel("sampel/detik (skala log)")
    ax.set_title("Training throughput (model.fit)")
    ax.legend(fontsize=8)
    for i, (cv, gv) in enumerate(zip(cvals, gvals)):
        ax.text(i + 0.2, gv, f"{gv / cv:.1f}x", ha="center", va="bottom", fontsize=8)

if cscl and gscl:
    ax = next(ax_iter)
    cm = {r["batch"]: r["samples_per_s"] for r in cscl["runs"]}
    gm = {r["batch"]: r["samples_per_s"] for r in gscl["runs"]}
    bs = sorted(set(cm) & set(gm))
    ax.plot(bs, [cm[b] for b in bs], "-o", label="CPU", color="#7a8b99")
    ax.plot(bs, [gm[b] for b in bs], "-o", label="GPU", color="#3b7dd8")
    ax.set_xscale("log", base=2)
    ax.set_yscale("log")
    ax.set_xlabel("ukuran batch")
    ax.set_ylabel("sampel/detik")
    ax.set_title("Titik potong CPU/GPU (training step)")
    ax.legend(fontsize=8)

if cinf and ginf:
    ax = next(ax_iter)
    for mname, style in (("cnn", "-o"), ("transformer", "-s")):
        if mname not in cinf["models"] or mname not in ginf["models"]:
            continue
        cm = {r["batch"]: r["latency_ms"] for r in cinf["models"][mname]["runs"]}
        gm = {r["batch"]: r["latency_ms"] for r in ginf["models"][mname]["runs"]}
        bs = sorted(set(cm) & set(gm))
        ax.plot(bs, [cm[b] / gm[b] for b in bs], style, label=mname)
    ax.axhline(1.0, color="crimson", ls="--", lw=1)
    ax.set_xscale("log", base=2)
    ax.set_yscale("log")
    ax.set_xlabel("ukuran batch")
    ax.set_ylabel("speedup GPU (CPU ms / GPU ms)")
    ax.set_title("Inference: speedup vs batch")

```

```

        ax.legend(fontsize=8)

fig.tight_layout()
fig.savefig(path)
plt.close(fig)
return path

# -----
# Orkestrator
# -----

def main():
    p = argparse.ArgumentParser(description="Benchmark AI CPU vs GPU (Keras 3 / TensorFlow)")
    p.add_argument("--device", choices=["cpu", "gpu", "both"], default="both")
    p.add_argument("--preset", choices=list(PRESETS), default="standard")
    p.add_argument("--only", default="", help=f"daftar kasus dipisah koma dari: {'', '.join(ALL_CASES)}")
    p.add_argument("--report", default="results", help="folder keluaran JSON/PNG")
    p.add_argument("--no-chart", action="store_true")
    p.add_argument("--chart-only", action="store_true", help="bangun ulang PNG dari summary.json yang sudah ada")
    p.add_argument("--no-isolate", action="store_true", help="jalankan semua kasus dalam satu proses per device (lebih cepat, "
                                                "tetapi hasil antar-kasus saling mencemari)")
    # argumen internal untuk proses anak
    p.add_argument("--child", action="store_true", help=argparse.SUPPRESS)
    p.add_argument("--json", help=argparse.SUPPRESS)
    args = p.parse_args()

    cases = [c.strip() for c in args.only.split(",") if c.strip()]
    unknown = [c for c in cases if c not in CASE_FN]
    if unknown:
        p.error(f"kasus tidak dikenal: {unknown}. Pilihan: {ALL_CASES}")
    cfg = PRESETS[args.preset]

    if args.child:
        run_child(args.device, cases, cfg, args.json)
        return

    outdir = Path(args.report)
    outdir.mkdir(parents=True, exist_ok=True)

    if args.chart_only:
        data = json.loads((outdir / "summary.json").read_text())
        png = write_chart(data.get("cpu"), data.get("gpu"), outdir / "cpu_vs_gpu.png")
        print(f"Grafik -> {png}")
        return

    devices = ["cpu", "gpu"] if args.device == "both" else [args.device]

    print(f"Preset : {args.preset}")
    print(f"Kasus : {'', '.join(cases)}")

```

```

print(f"Device : {' '.join(devices)}")
print(f"Keluaran : {outdir.resolve()}")

# Secara default setiap kasus dijalankan di prosesnya sendiri. Ini bukan
# kehati-hatian berlebihan: menjalankan seluruh kasus dalam satu proses
# membuat kasus belakangan mewarisi fragmentasi VRAM dan kondisi termal dari
# kasus sebelumnya. Pada mesin ini selisihnya terukur sampai ~35% untuk CNN.

payload = {}
for dev in devices:
    env = dict(os.environ, TF_CPP_MIN_LOG_LEVEL="2")
    if dev == "cpu":
        env["CUDA_VISIBLE_DEVICES"] = "-1"

    groups = [[c for c in cases] if not args.no_isolate else [cases]]
    merged = None
    for grp in groups:
        jpath = outdir / (f"{dev}.{grp[0]}.json" if len(grp) == 1 else f"{dev}.json")
        cmd = [sys.executable, os.path.abspath(__file__), "--child", "--device", dev,
               "--preset", args.preset, "--only", " ".join(grp), "--json", str(jpath)]
        if subprocess.call(cmd, env=env) != 0:
            print(f"\n[!] {dev}/{','.join(grp)} gagal; dilanjutkan tanpa kasus itu.")
            continue
        part = json.loads(jpath.read_text())
        if merged is None:
            merged = part
        else:
            merged["cases"].update(part["cases"])

    if merged is not None:
        (outdir / f"{dev}.json").write_text(json.dumps(merged, indent=2))
        payload[dev] = merged

rows = build_report(payload.get("cpu"), payload.get("gpu"))
print_report(rows)

summary = outdir / "summary.json"
summary.write_text(json.dumps(
    {"preset": args.preset, "rows": rows,
     "cpu": payload.get("cpu"), "gpu": payload.get("gpu")}, indent=2))
print(f"\nJSON gabungan : {summary}")

if not args.no_chart and "cpu" in payload and "gpu" in payload:
    png = write_chart(payload["cpu"], payload["gpu"], outdir / "cpu_vs_gpu.png")
    if png:
        print(f"Grafik : {png}")

if __name__ == "__main__":
    main()

```